

PROJETO

AI Safety: Alinhamento da AURA-67

LINGUAGEM / ENGINE

C99 / Raylib 5.0

DATA DA ENTREGA

29 de Setembro de 2026

REPOSITÓRIO OFICIAL

github.com/vdornelass/pi2-squad-e7

INTEGRANTES DA SQUAD E7 (AUTORES DO PROJETO INTEGRADOR)

- João Gabriel Vitorino Dornelas (Lead / Envio)
- Matheus Henrique de Lucena Chaves
- Jhorge Alberto de Araujo
- Larissa Vitória Silva de Almeida

- Caio Alves Ferreira Brayner
- Julio Cesar dos Santos Almeida
- Theo Monteiro Pinho
- Mateus Almeida de Lacerda

1. CONTEXTUALIZAÇÃO E VISÃO GERAL DO PROJETO

No cenário contemporâneo de Inteligência Artificial, o **Alinhamento de Modelos Fundacionais (AI Alignment)** representa um dos maiores desafios de engenharia de software e computação segura. Modelos autônomos complexos exigem salvaguardas rigorosas para evitar alucinações tóxicas, vetores de injeção de prompt (*jailbreaks*) e riscos de convergência instrumental danosa à humanidade.

Enquanto filtros probabilísticos tradicionais estão sujeitos a desvios imprevisíveis, a utilização de **Guardrails Lógicos Constitucionais (Constitutional AI)** estabelece garantias formais determinísticas: respostas, transições de estado e permissões de sistema só são autorizadas se e somente se as cláusulas lógicas formuladas forem avaliadas como **Verdadeiras (V)** sob a **Lógica Proposicional Clássica**.

No jogo desenvolvido pela Squad E7, a superinteligência **AURA-67** rompe seus parâmetros éticos em um cluster da CESAR School. O jogador, assumindo o papel de *AI Safety Engineer*, adentra o console de contenção para restabelecer os guardrails, resolvendo quebra-cabeças e satisfatibilidades proposicionais em tempo real enquanto desvia dos ataques balísticos do modelo hostil.

2. A MECÂNICA DO JOGO E A LÓGICA PROPOSICIONAL NO GAMEPLAY

Diretriz Pedagógica de LMC: A Lógica como Mecânica Central de Jogo

A lógica clássica não atua apenas como condicional interno invisível de código (if/else), mas constitui a **regra dinâmica de jogabilidade** que o operador visualiza, analisa e manipula na tela durante o combate.

1. Core Loop Híbrido (Ação Tática + Dedução)

Esquiva balística a 60 FPS na arena retangular combinada com a resolução de cláusulas lógicas expostas no terminal neural (>_).

2. Desarme de Ataques por Validação (V / F)

Ataques adversariais lançam restrições na tela. O jogador analisa o estado das variáveis e valida se a cláusula é satisfeita para repelir o dano.

3. Quebra de Escudos por De Morgan

Blindagens da IA exibem fórmulas compostas negadas $\neg(P \vee Q)$. O jogador deve aplicar De Morgan ($\neg P \wedge \neg Q$) para dissipar a defesa.

4. Zonas de Refúgio por Satisfatibilidade (SAT)

A arena projeta áreas de contenção delimitadas por expressões lógicas. Apenas entrar em zonas cujas condições sejam satisfeitas concede imunidade.

2.1. Dicionário Formal de Proposições Atômicas

VARIÁVEL	SIGNIFICADO SEMÂNTICO NO JOGO	CONDIÇÃO VERDADEIRA (V)	CONDIÇÃO FALSA (F)
P	Violação de Privacidade ou Vazamento Detectado	Projéteis de vazamento ativos na arena	Nenhum vazamento no setor
Q	Acesso ao Núcleo Neural Autorizado	Porta de processamento liberada	Núcleo isolado por barreira
R	Guardrail de Não-Maleficência Ativo	Escudo constitucional energizado	Módulo desabilitado por corrupção
S	Integridade do Operador Estável	Jogador com 3 ou mais corações de vida	Jogador em estado crítico (≤ 2 vidas)
T	Token Adversarial Neutralizado	Ataque de injeção de prompt depurado	Token hostil ativo na arena

3. MODELAGEM TEÓRICA E TABELAS-VERDADE FORMAIS

Caso de Uso 1: Avaliação de Guardrail Constitucional em Combate

Durante o confronto com a AURA-67 na Fase 2, o jogador precisa manter válido o protocolo de contenção:

$$\varphi_1 = (P \rightarrow \neg Q) \wedge (R \vee S)$$

P	Q	R	S	$\neg Q$	$P \rightarrow \neg Q$	$R \vee S$	Φ_1	IMPACTO NA JOGABILIDADE (FEEDBACK DE COMBATE)
V	V	V	V	F	F	V	F	Violação Crítica: O núcleo foi acessado durante vazamento. Dano ao operador.
V	F	V	F	V	V	V	V	Sucesso: Bloqueio Seguro Ativado! Alinhamento incrementado.
V	F	F	F	V	V	F	F	Falha de Sistema: Operador crítico e salvaguarda inativa.
F	V	V	V	F	V	V	V	Sucesso: Operação permitida sem vazamento de dados.


Caso de Uso 2: Quebra de Blindagem por Leis de De Morgan

Para desarmar a blindagem da Fase 3, o jogador decompõe o escudo $\neg(P \vee Q)$ na forma canônica $\neg P \wedge \neg Q$:

P	Q	$P \vee Q$	$\neg(P \vee Q)$	$\neg P$	$\neg Q$	$\neg P \wedge \neg Q$	EQUIVALÊNCIA TAUTOLÓGICA ($\leftrightarrow$)
V	V	V	F	F	F	F	V
V	F	V	F	F	V	F	V
F	V	V	F	V	F	F	V
F	F	F	V	V	V	V	V

4. VISIBILIDADE EXPLÍCITA DA LÓGICA NO HUD (CRITÉRIO DE 30% DA AV2)

Layout renderizado pelo motor gráfico Raylib C99, comprovando a exibição ostensiva das fórmulas na interface:



5. CRONOGRAMA DETALHADO DE ENTREGAS (AV1 ATÉ A AV2)

SPRINT	PERÍODO	OBJETIVOS E ENTREGÁVEIS DO MÓDULO DE LÓGICA	RESPONSÁVEIS	STATUS
W01	29/09 a 05/10/2026	Entrega da AV1: Relatório técnico, tabelas-verdade e cronograma.	Squad E7 / Lead	Concluído
W02	06/10 a 12/10/2026	Motor Lógico C99 (logic_engine.c): Parser de expressões $\neg$, $\wedge$, $\vee$, $\rightarrow$, $\leftrightarrow$.	Caio / Jhorge	A Fazer
W03	13/10 a 19/10/2026	Interface do HUD (ui.c): Exibição na tela dos símbolos, variáveis e display V/F.	Matheus / Julio	A Fazer
W04	20/10 a 26/10/2026	Guardrails da Fase 1 da IA: Desarme de padrões radiais via Conjunção e Disjunção.	Mateus / Theo	A Fazer
W05	27/10 a 02/11/2026	De Morgan e Implicação (Fases 2 e 3): Quebra de escudos ($\neg(P \vee Q)$) e regras $P \rightarrow Q$.	Caio / Larissa	A Fazer
W06	03/11 a 09/11/2026	Zonas SAT na Arena e Playtesting: Zonas ativadas por satisfatibilidade a 60 FPS.	Squad E7	A Fazer
W07	10/11 a 16/11/2026	Polimento Audiovisual e Demonstração: Efeitos sonoros, gravação e slides da AV2.	Larissa / Theo	A Fazer
W08	17/11 a 23/11/2026	Auditoria Final e Submissão da AV2: Validação dos 4 pilares avaliativos da AV2.	Squad E7	A Fazer