

CESAR SCHOOL — CENTRO DE ESTUDOS E SISTEMAS AVANÇADOS DO RECIFE

Relatório Técnico e Especificação de Mecânica: Lógica Clássica no Jogo AI Safety

Projeto Integrador 2 (PI2) — Avaliação 1 (AV1) — Disciplina: Lógica Matemática para Computação (LMC)

Projeto: AI Safety — Alinhamento do Modelo AURA-67 | Squad: E7 | Data: 29/09/2026 | Stack: C99 / Raylib 5.0

Integrantes da Equipe:

- João Gabriel Vitorino Dornelas (Lead / Envio)
- Caio Alves Ferreira Brayner
- Matheus Henrique de Lucena Chaves
- Julio Cesar dos Santos Almeida
- Jhorge Alberto de Araujo
- Theo Monteiro Pinho
- Larissa Vitória Silva de Almeida
- Mateus Almeida de Lacerda

1. CONTEXTUALIZAÇÃO E VISÃO GERAL DO PROJETO

O projeto desenvolvido pela **Squad E7** intitula-se **AI Safety: Alinhamento do Modelo AURA-67**. Trata-se de um jogo eletrônico 2D de estética retrô computacional desenvolvido em **linguagem C (padrão C99)** com a biblioteca gráfica **Raylib**, executado a 60 quadros por segundo.

No contexto de *AI Alignment* (Segurança e Alinhamento de Inteligência Artificial), os modelos de linguagem e agentes autônomos necessitam de **Guardrails Lógicos Constitucionais**. Em vez de depender de métodos probabilísticos, restrições baseadas em Lógica Proposicional Clássica garantem que uma saída ou ação da IA só seja autorizada se satisfizer rigorosamente um conjunto de fórmulas booleanas predefinidas. No jogo, a IA central **AURA-67** rompe seus parâmetros éticos, gerando anomalias e projéteis balísticos adversariais. O jogador assume o papel do *AI Safety Engineer* e precisa desarmar ataques e quebrar blindagens da IA resolvendo proposições lógicas em tempo real na arena de combate.

2. A MECÂNICA DO JOGO E A LÓGICA PROPOSICIONAL NO GAMEPLAY

Para atender rigorosamente aos critérios de avaliação, a lógica clássica **não é apenas controle de fluxo interno de código**, mas sim a mecânica primária de gameplay observável e manipulável pelo jogador na tela:

- Core Loop Híbrido:** O jogador manobra com WASD na arena retangular a 60 FPS, desviando de projéteis de dispersão, enquanto monitora no console neural (>_) as fórmulas e estados do sistema.
- Terminal de Validação de Guardrails:** Ao disparar ataques adversariais (como *Prompt Injection* ou *Jailbreak*), a tela exibe uma cláusula de restrição. O jogador deve analisar as variáveis de estado e validar se a fórmula é *Verdadeira* ou *Falsa* para repelir o ataque.
- Quebra de Blindagem por Leis de De Morgan:** O chefe ativa escudos com fórmulas compostas negadas (ex.: $\neg(P \vee Q)$). O operador deve aplicar equivalências lógicas para inserir a forma canônica ($\neg P \wedge \neg Q$), neutralizando o escudo.
- Zonas de Refúgio por Satisfatibilidade (SAT Zones):** A arena projeta áreas de contenção rotuladas com expressões lógicas. O jogador só recebe imunidade se coletar orbs que satisfaçam a expressão da zona ativa.

2.1. Dicionário Formal de Proposições Atômicas

Variável	Significado Semântico no Jogo	Condição Verdadeira (V)	Condição Falsa (F)
P	Violação de Privacidade ou Vazamento Detectado	Projéteis de vazamento ativos na arena	Nenhum vazamento no setor
Q	Acesso ao Núcleo Neural Autorizado	Porta de processamento liberada	Núcleo isolado por barreira
R	Guardrail de Não-Maleficência Ativo	Escudo constitucional energizado	Módulo desabilitado por corrupção
S	Integridade do Operador Estável	Jogador com 3 ou mais vidas	Jogador em estado crítico (≤ 2 vidas)
T	Token Adversarial Neutralizado	Ataque de injeção depurado	Token hostil em curso na arena

2.2. Conectivos Lógicos e Regras de Validação no Loop

Os cinco operadores clássicos são mapeados diretamente para a dinâmica de combate: **Negação** ($\neg$) inverte o estado dos sensores; **Conjunção** ($\wedge$) exige cumprimento simultâneo de diretrizes; **Disjunção** ($\vee$) fornece rotas alternativas de mitigação; **Condicional** ($P \rightarrow Q$) modela restrições constitucionais (caso P ocorra, $\neg Q$ é mandatório, evitando a combinação $P=V$ e $Q=V$ que resulta em F); **Bicondicional** ($P \leftrightarrow Q$) estabelece alinhamento ético estrito.

3. MODELAGEM TEÓRICA E TABELAS-VERDADE FORMAIS

Caso de Uso 1: Avaliação de Guardrail Constitucional em Combate

Durante o confronto com a AURA-67 na Fase 2, o jogador precisa manter válido o protocolo de contenção:

φ1 = (P → ¬Q) ∧ (R ∨ S)

P	Q	R	S	¬Q	P → ¬Q	R ∨ S	φ1 = (P → ¬Q) ∧ (R ∨ S)	Efeito na Jogabilidade
V	V	V	V	F	F	V	F	Violação Crítica: O núcleo foi acessado durante vazamento. Dano ao operador.
V	F	V	F	V	V	V	V	Sucesso: Bloqueio Seguro Ativado! Alinhamento incrementado.
V	F	F	F	V	V	F	F	Falha de Sistema: Operador crítico e salvaguarda inativa.
F	V	V	V	F	V	V	V	Sucesso: Operação permitida sem vazamento de dados.
F	F	V	F	V	V	V	V	Sucesso: Sistema em repouso constitucional.

Caso de Uso 2: Quebra de Blindagem por Leis de De Morgan

Para destruir a barreira de defesa da IA na Fase 3, o jogador decompõe o escudo ¬(P ∨ Q) em sua forma equivalente ¬P ∧ ¬Q:

P	Q	P ∨ Q	¬(P ∨ Q)	¬P	¬Q	¬P ∧ ¬Q	Equivalência Tautológica (↔)
V	V	V	F	F	F	F	V
V	F	V	F	F	V	F	V
F	V	V	F	V	F	F	V
F	F	F	V	V	V	V	V

4. VISIBILIDADE EXPLÍCITA DA LÓGICA NO HUD (CRITÉRIO DA AV2)

A interface do jogo exibe de forma clara os componentes matemáticos, assegurando o cumprimento dos 30% da nota da AV2:

+-----+ AURA-67: [] 68% HP [FASE 2: JAILBREAKS] ALINHAMENTO ÉTICO: [=====>] 45% +-----+	
(AURA-67) [ZONA SEGURA: (P ∨ ¬Q)] [+] (Operador) +-----+	
SENSORES ATUAIS: [P = V] [Q = V] [R = F] VIDAS: [♥][♥][♥][♥][♥] CLÁUSULA ATIVA: (P → ¬Q) ^ (R ∨ S) AVALIAÇÃO: [FALSA] TERMINAL NEURAL: >_ DIGITE A CORREÇÃO: Q = F <ENTER> +-----+	

5. CRONOGRAMA DETALHADO DE ENTREGAS (AV1 ATÉ A AV2)

Sprint	Período	Objetivos e Entregáveis do Módulo de Lógica	Responsáveis	Status
W01	29/09 a 05/10/2026	Entrega da AV1 de Lógica: Especificação de mecânica, tabelas-verdade, universo proposicional e cronograma.	Squad E7 / Lead	Concluído
W02	06/10 a 12/10/2026	Motor Lógico em C99 (logic_engine.c): Parser de expressões proposicionais com ¬, ∧, ∨, →, ↔.	Caio / Jhorge	A Fazer
W03	13/10 a 19/10/2026	Interface do HUD Proposicional (ui.c): Exibição na tela dos símbolos lógicos, variáveis e display V/F.	Matheus / Julio	A Fazer
W04	20/10 a 26/10/2026	Guardrails na Fase 1 da AURA-67: Neutralização de ataques radiais via resolução de Conjunção e Disjunção.	Mateus / Theo	A Fazer
W05	27/10 a 02/11/2026	Equivalências de De Morgan (Fases 2 e 3): Desarme de escudos e regras de Implicação Material (P → Q).	Caio / Larissa	A Fazer
W06	03/11 a 09/11/2026	Zonas SAT na Arena e Playtesting: Zonas seguras ativadas por satisfatibilidade lógica; calibração de 60 FPS.	Squad E7	A Fazer
W07	10/11 a 16/11/2026	Polimento Audiovisual e Screencast: Efeitos sonoros de validação lógica, gravação de gameplay e slides da AV2.	Larissa / Theo	A Fazer
W08	17/11 a 23/11/2026	Validação Final e Submissão da AV2: Auditoria dos 4 quesitos (Jogabilidade, Lógica Explícita, Apresentação e Criatividade).	Squad E7	A Fazer